

Testowanie algorytmu genetycznego

Tadeusz Puźniakowski

PJATK

11 marca 2023

Spis treści

- 1 Funkcje benchmarkowe
- 2 Metody testowania
- 3 Eksperymenty praktyczne
- 4 Kryteria zatrzymania
- 5 Koniec

Funkcja benchmarkowa

Funkcja benchmarkowa

Jest to funkcja, służąca do testowania algorytmu optymalizacyjnego.

Funkcja benchmarkowa

Funkcja benchmarkowa

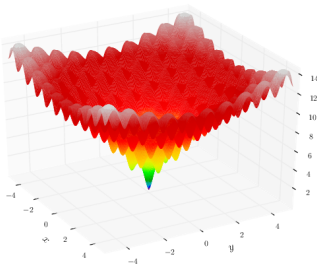
Jest wiele funkcji służących do testowania algorytmów optymalizacyjnych. Na tym wykładzie skupię się na jednej - dość ciekawej.

Funkcja benchmarkowa

Funkcja benchmarkowa – przykład

Funkcja Ackley-a

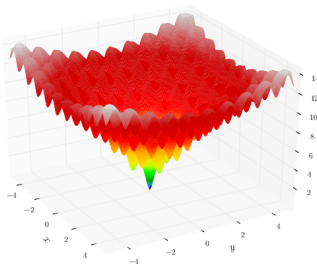
$$f(x, y) = -20 \exp \left(-0.2 \sqrt{0.5 (x^2 + y^2)} \right) - \exp (0.5 (\cos (2\pi x) + \cos (2\pi y))) + e + 20$$



Funkcja benchmarkowa

Funkcja benchmarkowa – Funkcja Ackley-a

Co można powiedzieć ciekawego o tej funkcji?



Spis treści

- 1 Funkcje benchmarkowe
- 2 Metody testowania**
- 3 Eksperymenty praktyczne
- 4 Kryteria zatrzymania
- 5 Koniec

Element losowości

Element losowości

Cechą algorytmów genetycznych jest to, że dla takiego samego problemu można obserwować różne zachowania się algorytmu.

Element losowości

Ocena algorytmu

Należy przeprowadzić wiele niezależnych uruchomień (co najmniej 25).

Element losowości

Ocena algorytmu

Jeśli stosujemy za każdym razem taką samą populację początkową, wtedy można powiedzieć, że algorytm ma określone właściwości dla takiej populacji.

****Raczej należy testować dla różnych populacji początkowych.**

Element losowości

Porównanie algorytmów

Czasami zdarza się porównywać dwa algorytmy. W takim przypadku dla każdej populacji początkowej mogą być uruchamiane oba algorytmy.

Element losowości

Porównanie algorytmów

Wyniki niezależnych uruchomień należy poddać analizie statystycznej, to znaczy wyznaczyć co najmniej:

- średnią
- odchylenie standardowe

Warto oczywiście stworzyć także histogram wyników.

Element losowości

Odchylenie standardowe — estymacja

Pierwiastek estymatora nieobciążonego wariancji:

$$s = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2}.$$

- x_i — i -ta wartość ciągu
- \bar{x} — średnia

Standard deviation

Krzywa zbieżności

Krzywa zbieżności

Wykres zmian jakości rozwiązania roboczego w czasie.

Może pokazywać na przykład najlepsze rozwiązanie, albo średnią jakości rozwiązań.

(Pokazać na przykładzie)

Koszt symulacji

Koszt symulacji a liczba generacji

W przypadku algorytmów ewolucyjnych liczba generacji nie zawsze jest dobrym kryterium określającym koszty działania algorytmu.

Odporność algorytmu

Zdolność opuszczania obszarów przyciągania maksimum lokalnego
Inaczej mówiąc odporność algorytmu.

Odporność algorytmu

Zdolność opuszczania obszarów przyciągania maksimum lokalnego

Można to testować tworząc populację początkową w taki sposób, aby żaden chromosom nie znajdował się w obszarze przyciągania optimum globalnego.

Jakie mogą być problemy?

Czy jest jakiś haczyk?

Odporność algorytmu

Zdolność opuszczania obszarów przyciągania maksimum lokalnego

Można to testować tworząc populację początkową w taki sposób, aby żaden chromosom nie znajdował się w obszarze przyciągania optimum globalnego.

Jakie mogą być problemy?

W praktyce czasami może być to trudne do wykonania (nie znamy optimum globalnego badanej funkcji).

Spis treści

- 1 Funkcje benchmarkowe
- 2 Metody testowania
- 3 Eksperymenty praktyczne**
- 4 Kryteria zatrzymania
- 5 Koniec

Testujemy algorytm

Różne metody selekcji

Przetestujemy różne metody selekcji. W celu porównania rozwiązań będziemy stosowali liczbę wywołań funkcji oceny.

Różne metody selekcji

Selekcja ruletkowa

Selekcja proporcjonalna (ruletkowa)

$$P_r(X) = \frac{\Phi(X)}{\sum_{Y \in P^t} \Phi(Y)}$$

gdzie Φ oznacza wartość funkcji oceny osobnika.

Test

Porównajmy co się będzie działo, jeśli do funkcji oceny dodamy jakąś stałą.

Różne metody selekcji

Selekcja ruletkowa

Zachowanie, które obserwowaliśmy wynika z tego, że mimo jednakowej różnicy wartości funkcji przystosowania osobników, proporcje liczby potomków są różne.

Różne metody selekcji

Selekcja rangowa

Zobaczmy jak będzie to wyglądało dla selekcji rangowej. (opcja do implementacji)

Sortujemy osobniki według wartości funkcji przystosowania i obliczamy prawdopodobieństwa w zależności od rangi. Dalej jak w selekcji ruletkowej.

Różne metody selekcji

Selekcja turniejowa

Podobnie dla selekcji turniejowej. Możemy porównać wersje losowania ze zwracaniem lub bez.

Różne metody sukcesji

Z elitą lub bez

Zobaczmy jaki wpływ ma zastosowanie elity.

Spis treści

- 1 Funkcje benchmarkowe
- 2 Metody testowania
- 3 Eksperymenty praktyczne
- 4 Kryteria zatrzymania**
- 5 Koniec

Kryteria zatrzymania

Dwie grupy kryteriów

- Monitorowanie wartości funkcji przystosowania i kryteria maksymalnego kosztu
- Monitorowanie zdolności eksploracyjnych (odporności na optima lokalne)

Pytanie - jakie kryterium stosowałem do tej pory?

Kryteria zatrzymania

Kryterium maksymalnego kosztu

Algorytm kończy pracę po zadanym czasie/liczbie iteracji.

Kryteria zatrzymania

Kryterium zadowalającego poziomu funkcji przystosowania

Algorytm osiągnie pewien poziom funkcji przystosowania –
zakończenie.

Kryteria zatrzymania

Kryterium minimalnej szybkości poprawy

Algorytm jest zatrzymywany, jeśli w kolejnych τ iteracjach nie uda się poprawić wyniku o więcej niż ϵ .

Kryteria zatrzymania

Kryterium zaniku różnorodności populacji

Jeśli populacja stanie się jednorodna, wtedy zdolności eksploracyjne ulegną znacznemu pogorszeniu – można wtedy zakończyć poszukiwania.

Kryteria zatrzymania

Zanik samoczynnie adoptowanego zasięgu operatora mutacji

Tego akurat nie omawiam, ale z przyzwoitości umieszczam.
Zainteresowanych odsyłam do literatury. (J. Arabas - „Wykłady z Algorytmów Ewolucyjnych”)

Spis treści

- 1 Funkcje benchmarkowe
- 2 Metody testowania
- 3 Eksperymenty praktyczne
- 4 Kryteria zatrzymania
- 5 Koniec**

Zakończenie

Dziękuję za uwagę.

Podsumowanie

Źródła

- Algorytmy genetyczne + struktury danych = programy ewolucyjne, Z. Michalewicz
- Wykłady z Algorytmów Ewolucyjnych, J. Arabas
- docs.opencv.org
- Wikipedia